

Classificação de Padrões, Perceptron, Descida do Gradiente e Backpropagation

Prof. Anderson Rocha

1 Classificação de padrões: visão geral

Dado $\mathbf{x} \in \mathbb{R}^d$, queremos decidir uma classe ω_j , $j \in \{1, \dots, C\}$. Num **discriminante linear**, usamos

$$g_j(\mathbf{x}) = \mathbf{w}_j^\top \mathbf{x} + b_j, \quad \hat{\omega}(\mathbf{x}) = \arg \max_j g_j(\mathbf{x}).$$

Para duas classes, a fronteira $g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = 0$ é um hiperplano.

Perdas e substitutos (intuição para o gradiente)

A 0–1 loss é não diferenciável. Substitutos comuns:

Perceptron: $\ell_{\text{perc}}(y, \mathbf{w}; \mathbf{x}) = \max(0, -y(\mathbf{w}^\top \mathbf{x} + b)),$

Hinge (SVM): $\ell_{\text{hinge}}(y, \cdot) = \max(0, 1 - y(\cdot)),$

Logística: $\ell_{\log}(y, p) = -[y \log p + (1 - y) \log(1 - p)], \quad p = \sigma(\mathbf{w}^\top \mathbf{x} + b).$

2 Perceptron: regra e *treinamento passo-a-passo no quadro*

Modelo (duas classes): $y \in \{-1, +1\}$,

$$\hat{y} = \text{sign}(\mathbf{w}^\top \mathbf{x} + b), \quad (\text{empacote viés}) \quad \tilde{\mathbf{x}} = \begin{bmatrix} 1 \\ \mathbf{x} \end{bmatrix}, \quad \tilde{\mathbf{w}} = \begin{bmatrix} b \\ \mathbf{w} \end{bmatrix}.$$

Atualização (taxa $\eta > 0$):

$$\text{se } \hat{y} \neq y : \quad \tilde{\mathbf{w}} \leftarrow \tilde{\mathbf{w}} + \eta y \tilde{\mathbf{x}}.$$

Teorema (clássico): Se o conjunto é linearmente separável, o algoritmo converge em passos finitos.

Exemplo numérico detalhado (com viés)

Escolha um conjunto simples (separável) para **produzir múltiplas atualizações** no quadro:

índice	$\mathbf{x}_i = (x_{i1}, x_{i2})$	y_i	$\Rightarrow \quad \tilde{\mathbf{x}}_i = (1, x_{i1}, x_{i2}).$
0	$(-2, -2)$	-1	
1	$(-2, -1)$	-1	
2	$(-1, -2)$	+1	
3	$(-1, -1)$	-1	

Inicialização: $\tilde{\mathbf{w}}^{(0)} = (0, 0, 0)$, $\eta = 1$. Percorra as amostras em ordem (e repita épocas). Calcule $u = \tilde{\mathbf{w}}^\top \tilde{\mathbf{x}}$, $\hat{y} = \text{sign}(u)$, e atualize quando errar.

Passos (mostre no quadro):

ép.	i	$\tilde{\mathbf{x}}_i = (1, x_1, x_2)$	y	u	$\hat{y}$	$\tilde{\mathbf{w}} \leftarrow \tilde{\mathbf{w}} + y\tilde{\mathbf{x}}_i$
0	0	(1, -2, -2)	-1	0	+1	(-1, 2, 2)
0	2	(1, -1, -2)	+1	-7	-1	(0, 1, 0)
1	2	(1, -1, -2)	+1	-1	-1	(1, 0, -2)
1	3	(1, -1, -1)	-1	3	+1	(0, 1, -1)
2	0	(1, -2, -2)	-1	0	+1	(-1, 3, 1)
2	2	(1, -1, -2)	+1	-6	-1	(0, 2, -1)

Após esses passos, o classificador já separa o conjunto (verifique rapidamente no quadro). *Pontos didáticos:* (i) importância do viés; (ii) geometria das atualizações (empurrar o hiperplano na direção da amostra mal classificada).

3 Descida do Gradiente (GD) e variantes

Ideia central

Minimizar $J(\theta)$ por iterações

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta),$$

onde η é a taxa de aprendizagem. Em dados, usamos a soma/ média de perdas por amostra.

Batch, Mini-batch, SGD

- **Batch GD:** usa todo o conjunto (estável, mas caro).
- **SGD:** usa uma amostra por vez (barato, ruidoso; bom para escapar de vales rasos).
- **Mini-batch:** compromisso prático (ex.: 32–512).

Comentários rápidos: escala das features, escolha de η , decaimento de taxa, momentum/Adam (mencione como extensões).

Exemplo de gradiente: Regressão Logística Binária

Dado $y \in \{0, 1\}$ e $p_{\theta}(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$ com $\sigma(u) = \frac{1}{1+e^{-u}}$, a perda média (entropia cruzada) é

$$J(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n \left[-y_i \log p_i - (1 - y_i) \log(1 - p_i) \right], \quad p_i = \sigma(\mathbf{w}^\top \mathbf{x}_i + b).$$

Gradientes (derivando no quadro via regra da cadeia):

$$\nabla_{\mathbf{w}} J = \frac{1}{n} \sum_{i=1}^n (p_i - y_i) \mathbf{x}_i, \quad \frac{\partial J}{\partial b} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i).$$

Atualização GD/SGD: $\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} J$, $b \leftarrow b - \eta \partial J / \partial b$.

4 Redes Neurais Multicamadas (MLP) e Backpropagation

Notação (camada l)

Ativações $\mathbf{a}^{(l)}$, pré-ativações $\mathbf{z}^{(l)}$, pesos $\mathbf{W}^{(l)}$, vieses $\mathbf{b}^{(l)}$:

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \phi(\mathbf{z}^{(l)}).$$

Saída $\mathbf{a}^{(L)}$; custo $J(\cdot)$ (ex.: MSE ou entropia cruzada).

Backprop: derivação compacta (para quadro)

Defina os “erros” por camada $\delta^{(l)} = \frac{\partial J}{\partial \mathbf{z}^{(l)}}$.

$$\text{Saída: } \delta^{(L)} = \nabla_{\mathbf{a}^{(L)}} J \odot \phi'(\mathbf{z}^{(L)}).$$

$$\text{Camadas ocultas: } \delta^{(l)} = (\mathbf{W}^{(l+1)\top} \delta^{(l+1)}) \odot \phi'(\mathbf{z}^{(l)}).$$

$$\text{Gradientes: } \frac{\partial J}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} \mathbf{a}^{(l-1)\top}, \quad \frac{\partial J}{\partial \mathbf{b}^{(l)}} = \delta^{(l)}.$$

Observação útil: com *entropia cruzada + sigmoid/softmax*, vale a simplificação $\delta^{(L)} = \mathbf{a}^{(L)} - \mathbf{y}$ (dispensa ϕ' na saída).

Exemplo numérico completo (uma iteração, 2–2–1)

Escolhas didáticas para facilitar conta na lousa:

- Ativações: $\phi = \sigma$ em todas as camadas;
- Custo: entropia cruzada binária $\Rightarrow \delta^{(L)} = \mathbf{a}^{(L)} - \mathbf{y}$;
- **Arquitetura:** entrada 2D $\rightarrow$ 2 neurônios ocultos $\rightarrow$ 1 saída.

Parâmetros iniciais (*anote exatamente estes valores no quadro*):

$$\mathbf{W}^{(1)} = \begin{bmatrix} 0.1 & -0.2 \\ 0.0 & 0.3 \end{bmatrix}, \quad \mathbf{b}^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{W}^{(2)} = \begin{bmatrix} 0.2 & -0.1 \end{bmatrix}, \quad b^{(2)} = 0,$$

amostra $\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ e alvo $y = 1$, taxa $\eta = 0.1$.

(1) Passagem direta

$$\mathbf{z}^{(1)} = \mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)} = \begin{bmatrix} 0.1 \\ 0.0 \end{bmatrix}, \quad \mathbf{a}^{(1)} = \sigma(\mathbf{z}^{(1)}) = \begin{bmatrix} 0.524979 \\ 0.5 \end{bmatrix}.$$

$$z^{(2)} = \mathbf{W}^{(2)} \mathbf{a}^{(1)} + b^{(2)} = 0.054996, \quad a^{(2)} = \sigma(z^{(2)}) = 0.513745.$$

Perda (CE): $J = -\log a^{(2)} = 0.666027$.

(2) Erro na saída

$$\delta^{(2)} = a^{(2)} - y = -0.486255.$$

(3) Gradientes da camada de saída

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \delta^{(2)} \mathbf{a}^{(1)\top} = \begin{bmatrix} -0.255273 & -0.243127 \end{bmatrix}, \quad \frac{\partial J}{\partial b^{(2)}} = \delta^{(2)} = -0.486255.$$

(4) Erro retropropagado ($\phi' = \sigma(1 - \sigma)$)

$$\delta^{(1)} = (\mathbf{W}^{(2)\top} \delta^{(2)}) \odot \phi'(\mathbf{z}^{(1)}) = \begin{bmatrix} -0.024252 \\ 0.012156 \end{bmatrix}.$$

(5) Gradientes da primeira camada

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(1)} \mathbf{x}^\top = \begin{bmatrix} -0.024252 & 0 \\ 0.012156 & 0 \end{bmatrix}, \quad \frac{\partial J}{\partial \mathbf{b}^{(1)}} = \delta^{(1)}.$$

(6) Atualização (GD, $\eta = 0.1$)

$$\mathbf{W}^{(2)} \leftarrow \mathbf{W}^{(2)} - \eta \frac{\partial J}{\partial \mathbf{W}^{(2)}} = \begin{bmatrix} 0.225527 & -0.075687 \end{bmatrix}, \quad b^{(2)} \leftarrow 0.048625.$$

$$\mathbf{W}^{(1)} \leftarrow \begin{bmatrix} 0.102425 & -0.2 \\ -0.001216 & 0.3 \end{bmatrix}, \quad \mathbf{b}^{(1)} \leftarrow \begin{bmatrix} 0.002425 \\ -0.001216 \end{bmatrix}.$$

(7) Checagem rápida (mesma amostra) Nova passagem direta:

$$\mathbf{z}^{(1)} = \begin{bmatrix} 0.104850 \\ -0.002431 \end{bmatrix}, \quad \mathbf{a}^{(1)} = \begin{bmatrix} 0.526189 \\ 0.499392 \end{bmatrix}, \quad z^{(2)} = 0.129498, \quad a^{(2)} = 0.532329.$$

Perda nova: $J' = -\log(0.532329) = 0.630493$ (**caiu**, como esperado).

Comentários didáticos rápidos

- A igualdade $\delta^{(L)} = a^{(L)} - y$ com CE + sigmoid/softmax simplifica muito a lousa.
- Mostrar *uma* iteração numérica completa ajuda a fixar direção de atualização.
- Destacar o papel do viés em *todas* as camadas.

O que vem por aí? CNNs

- Até aqui: MLPs ignoram estrutura espacial; param. densos $\Rightarrow$ muitos pesos.
- **CNNs**: convolução local compartilhando pesos + pooling = indutivo adequado p/ imagens.
- Gancho: filtros (3×3), receptivo local, *weight sharing* e invariança aproximada.